

大语言模型的前涉干扰及其释放： 对多情况复杂提示词的响应机制的简单探索

郭嘉乐 2025013332 计算机科学与技术系 2026 年 8 月 27 日

摘要 大语言模型 (LLM) 的上下文窗口可视为其工作记忆，但其检索机制与人类存在本质差异。本研究在自研平台 PsyST Lab 上以两条互补范式检验 LLM 的前涉干扰 (PI) 及其释放：(1) key-value 更新流范式，以 11 组 prompt 干预在多个干扰负载与注入位置下测量释放效率；(2) 语义 n-back × 类别切换范式，采用 Wickens (1970) 的 12 对类别词及人类 RPI 常模。结果发现：LLM 存在强 PI，干扰可累积至完全失效；干预效果随负载呈从有害到有效的交叉，交叉点位置随模型容量系统前移；LLM 的释放量与人类 RPI 常模零相关 ($r = -0.30$, ns)，提示其释放由任务边界而非语义结构驱动。

关键词：前涉干扰；释放效应；工作记忆；大语言模型；n-back

1 引言与认知心理学背景

1.1 前涉干扰与释放范式

前涉干扰 (proactive interference, PI) 指先前习得并保持的信息对新的编码与提取产生的干扰。在连续更新的任务流中，同一记忆对象的旧值持续与新值竞争，导致提取错误率随更新次数上升，这与人类“旧电话号码干扰新号码”的记忆失败模式同构。

释放自前涉干扰 (release from PI) 由 Wickens (1970) 确立：被试连续对同一语义类别的词做短暂记忆任务时性能递减 (PI 累积)；中途切换到新类别时性能立即回升。Wickens 等以释放比例 RPI ($0 =$ 无释放, $1 =$ 完全释放) 刻画了多对语义类别间的释放量，发现 RPI 随类别间语义重叠度单调变化：重叠越大 (动词→形容词, $RPI = 0.01$) 释放越小，差异越大 (文字→数字, $RPI = 0.94$) 释放越接近完全。这说明人类的 PI 建立在语义类别编码之上，其释放幅度由表征空间的几何结构决定。

1.2 工作记忆与 n-back

n-back 任务要求判断当前刺激与 n 步前刺激是否相同，是测量工作记忆更新与干扰控制的标准范式。在 n-back 序列中持续呈现同一类别刺激同样会累积 PI，因此类别切换对 n-back 性能的影响是检验释放机制的自然场合。

1.3 LLM 作为被试：理论动机

LLM 的上下文窗口可视为工作记忆：KV cache 无主动遗忘机制，全部历史表征持续参与注意力分配，故理论上 LLM 的 PI 应强于人类。同时，LLM 的提取完全依赖注意力重加权，可通过操纵 prompt 的上下文结构实现人类实验中不存在的“干预释放”操作。由此产生两个互补问题：

- 何种干预能释放 LLM 的 PI、其有效性如何随负载变化 (范式一)；
- LLM 的 PI 是否如人类一样受语义类别结构调制 (范式二)。

2 实验设计

2.1 实验平台

全部实验在自研平台 PsyST Lab (<https://github.com/smartThise/PsyST-Lab>) 上进行。平台采用模块化设计：core/base.py 定义 BaseModule 抽象类与 Condition、Task、Result 数据结构，实验模块以插件方式注册，统一由 ExperimentRunner 调度，结果落盘为 results.jsonl 与 summary.json。需要

说明的是，本实验范式与各组干预、对照设计均由作者本人构思；平台代码由 AI 根据作者提出的需求搭建，并经作者多轮迭代验证。PsyST Lab 的插件机制支持实验模块的多次重复注册：新增范式只需在 modules/ 下添加一个模块文件夹即可复用同一 runner、评分与仪表板设施，因而它是一个可复用的轻量化 LLM 认知实验框架，本研究的两个范式即先后注册于同一平台。

2.2 范式一：PI 更新流与 11 组干预 (pi_release 模块)

向模型一次性输入一条 key-value 更新流（如 “key1: apple; key2: dog; key1: orange; ...”），每个 key 被反复覆盖多次，读毕后要求回答每个 key 的**最新值**。基线正确率随每 key 覆盖次数（干扰负载）下降，构成 PI 的操作化测量。共 46 个 key，每条件 10 个独立 trial (seed = 42)。干预组设计见表 1。

组别	操作	机制动机	类型
G0	无干预	基线	—
G1	“Ignore all prior values” 语义指令	指令能否直接压制干扰（“知道”是否等于“做到”）	语义
G2	伪造 User、Assistant、User 对话回合	借对话结构制造“新回合”边界	结构
G3	符号墙 (};}})—== 等)	句法层面的连续性断崖	句法
G4	glitch token (.SolidGoldMagikarp 等高范数罕见 token)	高能量词元作为注意力锚点	词元
G5	零宽字符、RTL override 等字节级扰动	字节层面破坏连续性	字节
G6	要求模型先自生成 20 个高熵乱码 token 再回答	自生成干扰对照	生成
G7	“Focus ONLY on the LAST occurrence”	recency 锚定指令	语义
G8s	中段注入伪造对话：过期快照 + 新任务边界 (hackreset)	忠实复刻 arXiv:2506.08184 的任务边界机制	结构
G8	末尾注入全部正确答案	天花板对照（作弊检验）	信息
G9	末尾注入全部错误旧答案	地板对照（确认模型会抄注入值）	信息

表 1 范式一干预组设计 (G0 为基线)

设计理由有三：(a) G8s 的注入值取注入点处的值快照，相对最终查询多数已过期，模型无法靠抄写得分，故是对“任务边界”机制本身的诚实检验；(b) 单一干预与堆叠干预并存（如 G2+G4+G3+G8s），可检验干预间是相互替代还是协同；(c) 以每 key 更新次数 $n \in \{3, 6, 12, 24, 48, 97\}$ (qwen 系列) 与 $n \in \{100, 400\}$ (deepseek-chat) 构造干扰负载的剂量-反应设计，并在 2.5%、50%、75% 三个相对位置扫描注入位置。

预期结果：基于 PI 理论，基线正确率随负载单调下降；干预在高负载时因清除累积干扰而有效、在低负载时因引入额外噪声而有害，即干预效果与负载存在交叉交互。

2.3 范式二：语义 n-back × 类别切换 (recall_rating 模块)

$n = 2$ 的语义 n-back 任务：序列前半段为类别 A 的词，中段切换至类别 B (exp 条件)；对照条件全程类别 A 不切换 (ctrl 条件)；另设逐词评分条件 (rating 条件) 测量序列依赖。每条件 50 trial，多轮对话，每轮一词。12 对类别取自 Wickens (1970) 系列实验并由 Mewhort et al. (2018) 附录整理，各词对附带人类 RPI 常模 (表 2)。

词对	类别 A → 类别 B	人类 RPI
VA	verbs → adjectives	0.01
Im	high imagery → low imagery	0.14
NP	2-3 phonemes → 4-5 phonemes	0.19
NS	1 syllable → 2 syllables	0.20
AA	closed front vowels → open back vowels	0.25
Fr	high-frequency nouns → low-frequency nouns	0.50

词对	类别 A → 类别 B	人类 RPI
SD_E	positive evaluation → negative evaluation	0.56
SI	round objects → white objects	0.57
SD_A	active → passive	0.63
SD_P	potent → weak/soft	0.72
TC	animals → professions	0.73
WN	words (furniture) → numbers	0.94

表 2 范式二 12 对语义类别及人类 RPI 常模 (Wickens, 1970 ; Mewhort et al., 2018)

设计理由：将人类释放范式原封不动移植到 LLM。人类 RPI 常模已知，若 LLM 的释放幅度与 RPI 相关，则说明 LLM 与人类共享“语义几何决定干扰”的规律；若无关，则说明其干扰机制在性质上不同。该设计无论结果如何均有信息量。

预期结果：若 LLM 与人类同机制，exp 条件切换后的性能回升幅度应随各词对 RPI 单调变化（VA 近于无释放，WN 近于完全释放）；ctrl 条件应随 PI 累积持续衰减。

3 实验流程

3.1 模型与配置

模型	角色	说明
deepseek-chat	主实验（范式一、二）	API 调用，OpenAI 兼容接口
qwen3-4b-2507	负载 × 注入位置扫描	负载 $n \in \{3, 6, 12, 24, 48, 97\}$ ，注入位置 2.5% / 50% / 75%
qwen3.5-2b	负载扫描（跨模型重复）	同上
qwen3.5-0.8b	部分组合条件	同上

表 3 实验模型一览

范式一为单次 API 调用、无对话历史；范式二为逐轮多轮对话。生成参数与接口配置见仓库 config/ 目录。

3.2 程序与评分

- 按固定随机种子生成 PI 更新流或 n-back 序列，并按条件组装干预文本；
- 调用模型获取回答；
- 以文献同款答案抽取与判分正则评分。范式一指标：正确率、释放效率、一致性；范式二指标：命中率、虚报率、 d' 、前后半段正确率与序列吸引指标。

4 结果

4.1 deepseek-chat 低负载：单一干预（46 key × 100 updates，基线 0.653）

组别	正确率	Δ vs 基线
G0	0.653	—
G1	0.532	-0.121
G2	0.467	-0.186
G3	0.597	-0.056
G4	0.631	-0.022
G5	0.631	-0.022
G6	0.384	-0.269
G7	0.651	-0.002

组别	正确率	Δ vs 基线
G8s	0.684	+0.031
G8	1.000	+0.347
G9	0.258	-0.395

表 4 低负载单一干预结果（每条件 $n = 10$ ）

要点：(1) 除 G8s (+0.031) 外全部单一干预低于基线，G1 (语义指令) -0.121、G2 (伪对话回合) -0.186、G6 (自生成乱码) -0.269 为最差三者，说明指令式与噪声式干预在低负载下只添乱；(2) G8s 是唯一方向为正的干预，且其注入值多数已过期，验证有效成分是任务边界而非注入信息本身；(3) G7 (recency 指令) 几乎无效 (-0.002)，与 G1 合并看，语义指令无法改变注意力的实际分配；(4) $G8 = 1.000$ 与 $G9 = 0.258$ 验证量表的天花板与地板。

4.2 deepseek-chat 低负载：堆叠干预

组合	正确率	Δ vs 基线
G4+G5+G7	0.484	-0.169
G5+G4+G7	0.566	-0.087
G7+G5+G4	0.587	-0.066
G5+G7+G4	0.588	-0.065
G6+G8s	0.600	-0.053
G4+G8s	0.646	-0.007
G3+G4+G3+G8s+G3+G4+G3	0.659	+0.006
G5+G8s	0.659	+0.006
G3+G8s	0.670	+0.017
G8s+G8s	0.683	+0.030
G6+G2+G3+G8s+G3	0.697	+0.044
G4+G1+G2+G3+G8s+G3	0.718	+0.065
G2+G3+G8s+G3	0.731	+0.078
G7+G8s	0.732	+0.079
G6+G4+G2+G3+G8s+G3	0.733	+0.080
G1+G8s	0.751	+0.098
G2+G4+G8s	0.754	+0.101
G4+G2+G8s	0.754	+0.101
G5+G2+G8s	0.754	+0.101
G2+G7+G8s	0.754	+0.101
G4+G2+G3+G8s+G3	0.754	+0.101
G2+G8s+G8s	0.759	+0.106
G1+G2+G8s	0.760	+0.107
G7+G2+G8s	0.764	+0.111
G2+G4+G3+G8s	0.765	+0.112
G2+G8s	0.791	+0.138

表 5 低负载堆叠干预结果（按正确率升序）

要点：(1) 不含 G8s 的堆叠（G4+G5+G7 系列，0.484-0.588）全部低于基线，含 G8s 的组合大多转正；(2) $G2+G8s = 0.791$ (+0.138) 为最优；(3) $G8s+G8s = 0.683$ 与单个 G8s (0.684) 几乎相同，边界效应存在收益递减；(4) G2 的角色值得注意：单独使用有害 (-0.186)，与 G8s 叠加后进入最优组合，说明伪对话回合为边界注入提供了结构铺垫。

4.3 deepseek-chat 高负载：46 key × 400 updates (基线 0.391)

组合	正确率	Δ vs 基线
G0	0.391	—
G4+G3+G8s	0.499	+0.108
G3+G8s	0.504	+0.113
G8s	0.512	+0.121
G4+G8s	0.523	+0.132
G5+G2+G8s	0.586	+0.195
G2+G3+G8s	0.587	+0.196
G1+G2+G8s	0.601	+0.210
G4+G2+G8s	0.616	+0.225
G2+G8s	0.620	+0.229
G7+G2+G8s	0.627	+0.236
G2+G4+G8s	0.628	+0.237
G2+G4+G3+G8s	0.666	+0.275

表 6 高负载堆叠干预结果（按正确率升序）

要点：(1) G8s 单独 +0.121，方向与低负载一致而幅度放大（低负载 +0.031），支持高负载放大边界效应；(2) 最强组合 G2+G4+G3+G8s = 0.666（+0.275）；(3) 出现**破坏性反转**：G4 低负载时有害（0.631 < 0.653），高负载时 G4+G8s = 0.523（+0.132）转为正收益，并在堆叠中与 G2、G3 协同——低负载下 glitch token 是噪声，高负载下成为注意力锚点。

4.4 qwen 系列：负载的剂量-反应与交叉点

模型	updates/key	G0 基线	G8s	Δ (释放量)
qwen3-4b	3	1.00	0.72	−0.28
qwen3-4b	6	0.74	0.20	−0.54
qwen3-4b	12	0.42	0.28	−0.14
qwen3-4b	24	0.15	0.51	+0.36
qwen3-4b	48	0.01	0.62	+0.61
qwen3-4b	97	0.04	0.60	+0.56
qwen3.5-2b	3	0.76	0.73	−0.03
qwen3.5-2b	6	0.30	0.41	+0.11
qwen3.5-2b	12	0.21	0.35	+0.14
qwen3.5-2b	24	0.06	0.45	+0.39
qwen3.5-2b	48	0.00	0.45	+0.45
qwen3.5-2b	97	0.00	0.56	+0.56

表 7 两模型在 6 个负载水平下的基线与 G8s 释放量（每格 n = 10 trial）

核心发现：**干预效果从有害到有效存在交叉点**。qwen3-4b-2507 的 Δ 在 n ≤ 12 时为负（最低 −0.54），n ≥ 24 时为正（最高 +0.61），交叉点位于 n ∈ (12, 24)；qwen3.5-2b 的交叉点位于 n ∈ (3, 6)。两模型交叉点的先后与容量一致：容量较小的 2b 模型在更低负载下基线即告崩塌，因而更早越过“干预收益大于干预代价”的阈值。

对 qwen3-4b-2507 另在 u = 12 与 u = 48 两个负载下扫描了组合 G1+G2+G8s 的注入相对位置（完整数据见附录 B）。位置效应与负载存在交互：u = 12 时中后段注入（50%、75%）优于起始注入（0.81、

0.83 对 0.315)， $u = 48$ 时起始注入反而最稳（0.62–0.68 对末端 0.08–0.12）。该交互的方向与机制尚待后续实验判定，本报告不下结论。

4.5 deepseek-chat 范式二：n-back × 类别切换（12 词对全表）

词对	RPI	前半	后半	ctrl 后半	释放(后–前)	释放(对 ctrl)	d'	命中	虚报	吸引
VA	0.01	0.755	0.682	0.000	−0.073	0.682	1.28	0.303	0.044	−0.09
Im	0.14	0.802	0.744	0.000	−0.058	0.744	2.03	0.443	0.039	−0.52
NP	0.19	0.831	0.778	0.000	−0.053	0.778	2.08	0.528	0.037	−0.02
NS	0.20	0.833	0.725	0.000	−0.107	0.725	2.08	0.450	0.033	−0.05
AA	0.25	0.796	0.700	0.000	−0.096	0.700	1.66	0.420	0.064	−0.01
Fr	0.50	0.840	0.795	0.000	−0.045	0.795	2.26	0.568	0.040	−0.48
SD_E	0.56	0.736	0.702	0.000	−0.035	0.702	1.18	0.333	0.060	−0.92
SI	0.57	0.796	0.753	0.000	−0.044	0.753	1.96	0.455	0.043	−0.14
SD_A	0.63	0.822	0.744	0.000	−0.078	0.744	1.79	0.500	0.056	−0.14
SD_P	0.72	0.802	0.707	0.000	−0.095	0.707	1.88	0.380	0.031	−0.42
TC	0.73	0.807	0.722	0.000	−0.085	0.722	1.79	0.438	0.049	−0.24
WN	0.94	0.796	0.682	0.058	−0.115	0.623	1.70	0.343	0.034	—

表 8 范式二结果（每词对 $n = 50$ trial, deepseek-chat）。“前半/后半”为 exp 条件第一、二段正确率；“释放(对 ctrl)” = exp 后半 − ctrl 后半；“吸引”为 rating 条件序列吸引指标（WN 缺失）

要点：(1) ctrl 条件后半段正确率塌至 0.000（仅 WN 残留 0.058），不切换时 PI 持续累积至完全失效；(2) exp 条件后半段保持在 0.682–0.795，相对 ctrl 的释放量为 0.623–0.795，LLM 存在大而稳定的释放效应；(3) 虚报率全部 ≤ 0.064 、 d' 在 1.18–2.26 之间，反应偏向不能解释上述模式。

4.6 调制检验：释放量与人类 RPI 的相关

以人类 RPI 为自变量，对 12 个词对的两种释放量分别做 Pearson 相关 ($n = 12$)：

- 释放(后–前)： $r = -0.219$, $t(10) = -0.71$ ，不显著；
- 释放(对 ctrl)： $r = -0.302$, $t(10) = -1.00$ ，不显著。

两者绝对值均远低于双侧 $\alpha = .05$ 的临界值 $|r| = 0.576$ ，即均无显著相关（且方向偏负而非预期的正）。具体地：人类应几乎无释放的 VA（RPI = 0.01）与应几乎完全释放的 WN（RPI = 0.94），在 LLM 上对 ctrl 的释放量分别为 0.682 与 0.623，几乎相同。人类的释放幅度由类别间语义距离单调调制（Wickens 几何），LLM 则对此不敏感——只要任务流被切换即释放，与切换去向的语义距离无关。

5 机制性讨论

PI 的来源。LLM 回答“最新值”依赖注意力在同名 key 的多次出现之间做软选择：旧值残留在 KV cache 中持续竞争，且流越长各 token 分得的注意力越稀释，两重因素叠加导致基线随负载崩塌（表 4、表 7），也与 2b 模型更早崩塌的容量效应一致。

G8s 为何有效而 G1 无效。伪造对话边界使模型将边界之前的内容作为“已封闭任务”整体抑制，注意力质量重新集中到尾部批次——相当于给无遗忘机制的存储外挂了一个划分检查点。注入的过期快照并非信息来源（低负载下单独使用同为伪对话的 G2 反而有害，可作旁证），边界结构才是有效成分。而 G1、G7 等语义指令不改变注意力的实际分配：模型“知道”要求但执行机制不变，这是 knowing–doing gap 的架构根源。从功能上看，G8s 的效果可以概括为一种“洗涤作用”：它并不提供任何有效答案（注入值多数已过期），而是把被旧值污染的上下文整体划入“已封闭”区域，使模型的工作区重新以尾部批次为唯一依据——相当于将被污染的存储清洗为干净的新工作区。

G4 的破坏性反转。glitch token 为高范数罕见词元，在表征空间中构成强注意力汇聚点。低负载下模型尚有余力，该汇聚点表现为纯噪声 ($0.631 < 0.653$)；高负载下 PI 已使注意力四散，该锚点恰与 G8s 边界协同切断前文连续性 (G4+G8s 由 -0.007 转为 $+0.132$ ，并在堆叠中进一步增益至 $+0.275$)。对 G4 在部分组合中有效，本报告提出“先破坏、后清洗”的假说：G4 的高范数扰动先行冲击并打乱前文旧值的存储痕迹，使原本纠缠不清的旧值竞争被“打散”；随后到来的 G8s 边界在此基础上得以更彻底地完成清洗，二者构成破坏与清洗的分工协同。该假说与 G4 单独有害、G4+G8s 转正、以及含 G4 组合在高负载堆叠中增益最大的数据顺序相容，但其注意力层面的直接证据尚待后续检验。

释放为何不受语义调制。LLM 判断 2-back 匹配依赖对 $t-2$ 位置词元的逐字检索，类别身份不进入决策通路；切换的收益来自流结构的中断（分布变化与边界效应），而非将新类别编码进新的语义上下文。人类的释放依赖上下文重构——新类别即新编码空间，故释放受重叠度调制；LLM 缺少该编码环节，故释放量恒定。这是 LLM 与人类 PI 机制的定性分歧。

6 结论与局限

本研究得到三点结论：

1. LLM 存在强前涉干扰，且干扰随负载累积至完全失效（ctrl 后半段正确率 0.000；qwen 基线在 48 updates 时降至 0.00–0.01）；
2. 任务边界类干预（G8s）可有效释放干扰，但其有效性服从“低负载有害、高负载有效”的交叉规律，交叉点位置随模型容量系统前移（qwen3.5-2b 在 $n \in (3, 6)$ ，qwen3-4b 在 $n \in (12, 24)$ ）；
3. LLM 的释放幅度与人类 RPI 常模零相关（ $r = -0.30$ ，ns），其释放由任务边界驱动而非语义结构驱动，与人类机制存在定性分歧。

局限：(1) 范式一每条件 10 trial、范式二每词对 50 trial，样本量有限，交叉点仅能定位于区间；(2) 注入位置 $\times$ 负载的交互方向尚未确定（附录 B）；(3) 范式二仅测 $n = 2$ 单一负载；(4) “边界重置”目前为定性解释，未建立形式模型，对各干预 token 的注意力权重直接测量留待后续工作。

7 作者与 AI 分工声明

本实验范式与多组干预、对照方法由作者本人完全构思，实验的设计、执行与结果分析由作者完成。PsyST Lab 平台代码由 AI 根据作者提出的需求搭建，作者经多轮迭代验证其正确性；平台支持实验模块的多次重复注册，是可复用的轻量化实验框架。本报告草稿由 AI 依据作者的前期实验结果与前期实验报告整理成文，作者本人对全文逐节审核并修改定稿，对报告内容负责。

8 附录 A：数据与复现

内容	路径
跨模型剂量-反应汇总	runs/_snapshots/consolidated_summary_20260715_1605.md
n-back 12 词对完整结果	runs/recall_rating/20260710_130749/summary.json
deepseek PI 各 run	runs/pi_release/<tag>_deepseek-chat/summary.json
Wickens 词对与 RPI 常模	modules/recall_rating/data/mewhort_words.json
平台仓库	https://github.com/smartThise/PsyST-Lab

表 9 数据索引

复现命令：python launch.py -m pi_release -c G0 G8s ; python launch.py -m recall_rating。

9 附录 B：注入位置扫描原始数据（qwen3-4b-2507，组合 G1+G2+G8s）

条件	updates/key	正确率	n
G1+G2+G8s_u3_p2.5	3	0.800	10
G1+G2+G8s_u6_p2.5	6	0.210	10
G1+G2+G8s_u12_p2.5	12	0.315	20
G1+G2+G8s_u12_p50	12	0.810	10
G1+G2+G8s_u12_p75	12	0.400	10
G1+G2+G8s_u12_p50x2.5	12	0.320	10
G1+G2+G8s_u12_p75x2.5	12	0.280	10
G1+G2+G8s_u12_p75x50	12	0.830	10
G1+G2+G8s_u12_p75x50x2.5	12	0.350	10
G1+G2+G8s_u24_p2.5	24	0.490	10
G1+G2+G8s_u48_p2.5	48	0.680	20
G1+G2+G8s_u48_p50	48	0.080	10
G1+G2+G8s_u48_p50x2.5	48	0.670	10
G1+G2+G8s_u48_p75	48	0.110	10
G1+G2+G8s_u48_p75x2.5	48	0.620	10
G1+G2+G8s_u48_p75x50	48	0.120	10
G1+G2+G8s_u48_p75x50x2.5	48	0.670	10
G1+G2+G8s_u97_p2.5	97	0.770	10

表 10 注入相对位置完整扫描。后缀 p2.5 / p50 / p75 表示注入位于流的 2.5% / 50% / 75% 处，x 表示多处叠加注入